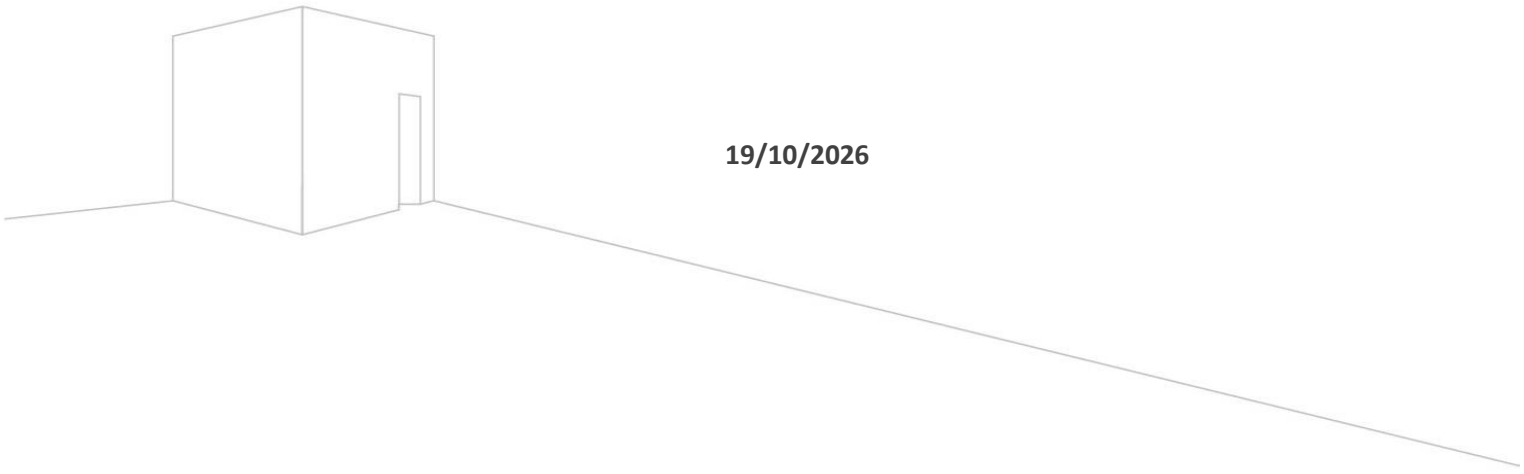
Predicción de viajes de taxi por zona y hora

Asignatura: Big Data TI3025

Nombre del académico: Paulo Simunovic Oyarzún

Nombre del estudiante: Vicente Yagello



19/10/2026

Contenido

I. Introducción. 3
1. Problema y herramientas seleccionadas....3
2. Resultado principal y entrega....3
II. Desarrollo 4
3. Arquitectura disponibilidad y seguridad 4
4. Preparación y almacenamiento de los datos 5
5. Análisis descriptivo....6
6. Diseño del modelo y validación temporal....7
7. Resultados e interpretación 8
8. Ejecución cloud y uso del prototipo....9
9. Planificación y seguimiento individual 10
III. Conclusiones....11
IV. Referencias bibliográficas....12

I. Introducción.

Este trabajo desarrolla un pipeline en Google Cloud para analizar y predecir el número de viajes de taxis amarillos que comienzan en cada zona de Nueva York durante una hora. Se procesaron 9.071.242 registros de enero a marzo de 2022; después de validar fecha y zona, quedaron 8.958.864 viajes. Las transformaciones, el análisis descriptivo y el entrenamiento se ejecutaron en BigQuery.

El objetivo es integrar almacenamiento eficiente, procesamiento distribuido, controles de calidad y un modelo evaluado cronológicamente. El prototipo permite consultar predicciones históricas por zona y hora. Su aplicación potencial es apoyar la distribución de una flota, sin confundir viajes realizados con solicitudes no atendidas ni con el número de vehículos necesarios.

1. Problema y herramientas seleccionadas

Se eligió movilidad urbana porque ofrece millones de eventos, zonas oficiales y una variable objetivo interpretable. Frente a consumo eléctrico o comercio minorista, la fuente TLC permite relacionar directamente tiempo, territorio y volumen de actividad. Los datos son públicos, pero su cobertura se limita a taxis amarillos y a un trimestre histórico [1].

BigQuery sandbox reúne almacenamiento columnar, SQL distribuido y BigQuery ML en un solo entorno. Python y el notebook actúan como clientes; no simulan localmente un entrenamiento presentado como cloud. Esta alternativa reduce la administración de infraestructura y permite realizar el experimento sin activar facturación, sujeto a las cuotas y retención del servicio [2].

2. Resultado principal y entrega

La regresión obtuvo un RMSE de 9,81 viajes por zona y hora, frente a 10,75 de una referencia semanal: una reducción del 8,80 %. Sin embargo, la referencia semanal obtuvo mejores MAE y WAPE. Por tanto, la decisión depende del costo de los errores grandes y no de una supuesta superioridad en todas las métricas.

El repositorio contiene únicamente pipeline.py, proyecto.ipynb, configuracion.json, resultados.json, demanda_horaria.parquet y este informe PDF. El notebook incluye las instrucciones de ejecución y las comprobaciones; no se requieren documentos auxiliares.

https://github.com/c3cla/bigdata-ev2-vicente

II. Desarrollo

3. Arquitectura disponibilidad y seguridad

La solución utiliza el proyecto round-pen-449819-s1, dataset movilidad_urbana, ubicación US. Bronze conserva los registros originales; Silver valida el universo; Gold completa los conteos por zona y hora; la capa de variables alimenta el modelo y la evaluación.

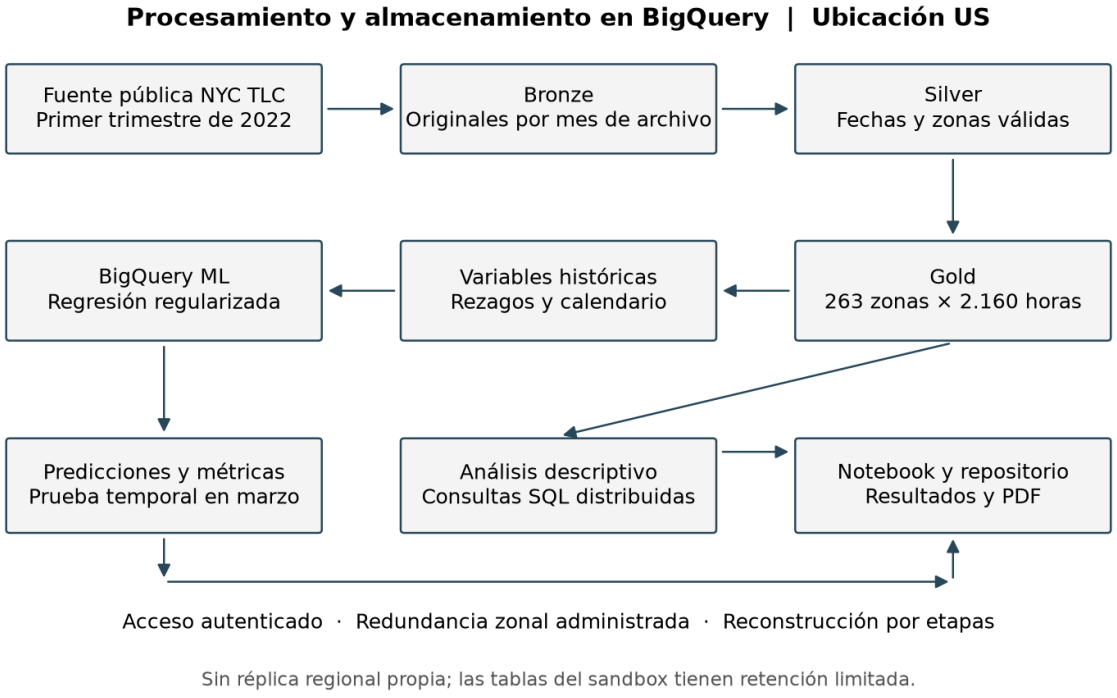


Figura 1. Pipeline batch implementado en BigQuery. Python coordina las etapas y exporta resultados.

El procesamiento batch corresponde a archivos históricos publicados con retraso. BigQuery distribuye las consultas y administra el escalamiento y la redundancia zonal. No se implementó réplica entre regiones ni conmutación regional automática: la etiqueta US no prueba por sí sola recuperación ante una pérdida regional [3].

Las etapas reemplazan sus resultados sin anexar duplicados y Python realiza hasta cuatro intentos ante errores transitorios. Un fallo exige reconstruir la etapa afectada y sus dependientes; no existe una transacción global. Las tablas y el modelo permanecen si se cierra el cliente, pero caducan según la retención del sandbox.

Se utilizó la sesión Google del autor, sin publicar claves. Para automatización futura se propone BigQuery Job User en el proyecto y Data Editor restringido al dataset; no se presenta una cuenta de servicio como ya configurada. El cliente limita cada consulta a 20 GB; esto complementa, pero no sustituye, las cuotas gratuitas [2, 4].

4. Preparación y almacenamiento de los datos

La fuente es bigquery-public-data.new_york_taxi_trips.tlc_yellow_trips_2022. Se seleccionaron los meses de archivo 1 a 3. Silver exige inicio desde el 1 de enero, anterior al 1 de abril, y zona de origen entre 1 y 263.

Control	Registros	Tratamiento
Originales	9.071.242	Conservar en Bronze
Fecha nula / fuera del periodo	0 / 110	Excluir del universo
Zona inválida	112.268	Excluir del universo
Importe negativo	48.588	Auditar; no es predictor
Llegada anterior a salida	4.685	Auditar; no usar duración
Distancia negativa	0	Control de calidad
Viajes válidos	8.958.864	Universo analítico

Se excluyeron 112.378 registros, el 1,24 %. Los controles pueden superponerse; no deben sumarse como categorías excluyentes. No se deduplica por zona y hora porque múltiples viajes pueden compartir ambas y no existe una clave única confiable. Los importes y duraciones anómalos no invalidan automáticamente un inicio útil para contar viajes.

Bronze se particiona por mes entero de archivo y se agrupa por zona. Silver, Gold, variables y predicciones usan rangos enteros de zona de amplitud 16 y clustering temporal. Las primeras particiones por fechas de 2022 caducaban en el sandbox y dejaban tablas vacías; los rangos enteros resolvieron el problema sin cambiar los datos analizados.

Gold cruza 263 zonas con 2.160 horas: 568.080 filas, incluyendo ceros mediante LEFT JOIN. Así, un rezago de 24 filas equivale a 24 horas. El almacenamiento cloud es columnar; el respaldo demanda_horaria.parquet usa Snappy. Se verificaron volumen, unicidad, cobertura y las huellas de las 263 zonas.

La reconstrucción desde los Parquet oficiales actuales mostró dos viajes adicionales frente a la copia BigQuery. Se conciliaron las dos series afectadas y el respaldo conserva el universo del experimento; la diferencia se registra en resultados.json. Se mantienen las etiquetas temporales de la fuente sin una segunda conversión de huso; el horario de verano exige revisión antes de una operación real.

5. Análisis descriptivo

Las agregaciones se ejecutaron con SQL sobre Gold. El promedio diario fue 99.543 viajes, la mediana 100.050, el mínimo 34.064 y el máximo 127.799. Las diez zonas de mayor actividad concentraron el 36,61 % del volumen, por lo que una asignación uniforme de vehículos no refleja la distribución observada.

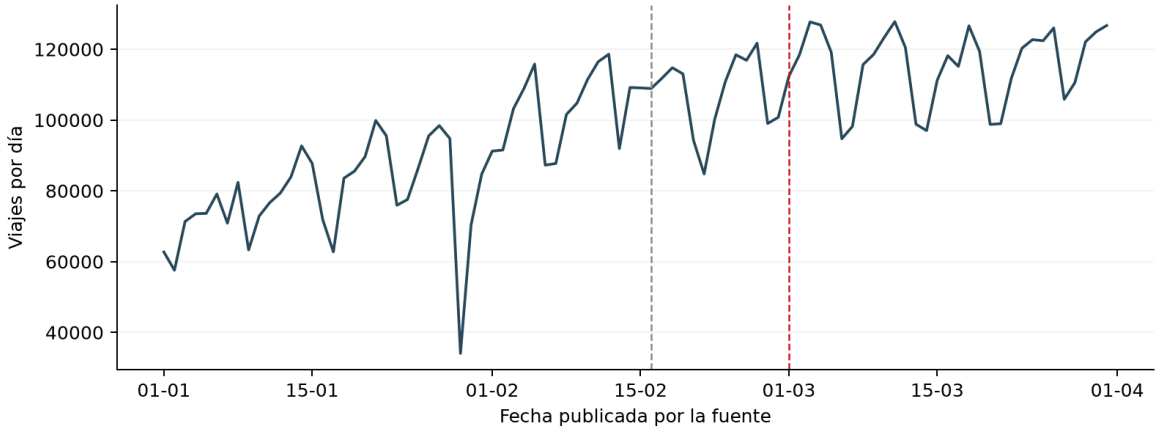


Figura 2. Viajes diarios; líneas verticales: comienzo de validación y prueba.

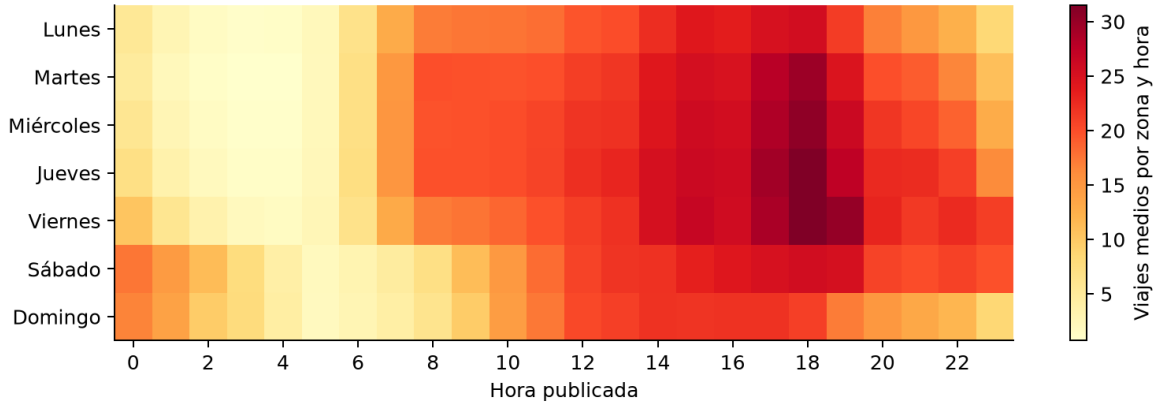


Figura 3. Intensidad media por zona, día y hora, incluyendo horas sin viajes.

El 64,73 % de las celdas zona–hora tiene cero viajes. Se utiliza WAPE agregado en lugar de MAPE por observación, que divide por cero. Los patrones justifican rezagos diarios y semanales, sin atribuir causalidad a clima, políticas o eventos que no fueron medidos.

6. Diseño del modelo y validación temporal

La variable objetivo es el conteo de inicios por zona y hora. Se predice una hora adelante suponiendo disponibles las observaciones anteriores. Se excluyen del modelamiento tarifas, propinas, destino y duración del mismo viaje, porque podrían aportar información posterior al momento de decisión.

Variables	Construcción
rezago_1, rezago_24, rezago_168	Viajes de 1, 24 y 168 horas antes
media_24h	Promedio de las 24 horas anteriores; excluye el objetivo
seno_hora, coseno_hora	Codificación cíclica de la hora
zona, dia_semana	Categorías conocidas al emitir el pronóstico

Se entrenó una regresión lineal BigQuery ML con regularización L2 = 1 y separación CUSTOM mediante una columna booleana de validación. BigQuery ML administra la codificación categórica y el tratamiento numérico. La primera semana se reserva para formar rezagos; no se seleccionan hiperparámetros mirando marzo [5].

Conjunto	Periodo 2022	Filas
Entrenamiento	8 de enero a 15 de febrero	246.168
Validación	16 a 28 de febrero	82.056
Prueba	1 a 31 de marzo	195.672

El modelo se mantiene fijo en marzo, pero los rezagos pueden incorporar horas de marzo que ya transcurrieron. Es una evaluación secuencial de una hora adelante, no un pronóstico de todo el mes emitido en febrero. Las predicciones negativas se recortan a cero antes de evaluar.

El siguiente fragmento del pipeline documenta cómo se evita incluir el valor objetivo en la media móvil:

```
AVG(viajes) OVER (
  PARTITION BY zona_id ORDER BY hora
  ROWS BETWEEN 24 PRECEDING AND 1 PRECEDING
) AS media_24h
```

El notebook comprueba los rezagos y la media contra el respaldo completo. Las cinco validaciones SQL revisan volumen, conservación, predicciones válidas, igualdad del conjunto de prueba y ausencia de variables faltantes.

7. Resultados e interpretación

Modelo	MAE	RMSE	WAPE	R^2
Regresion lineal BQML	3,301	9,809	18,04 %	0,9678
Estacional semana anterior	3,186	10,755	17,41 %	0,9613
Persistencia ultima hora	4,416	14,270	24,13 %	0,9319
Estacional dia anterior	4,688	17,153	25,62 %	0,9017

Los cuatro métodos usan las mismas 195.672 filas de prueba. MAE expresa el error absoluto medio; RMSE penaliza más los errores grandes; WAPE relaciona el error absoluto total con el volumen observado; R^2 compara el error cuadrático con una predicción constante.

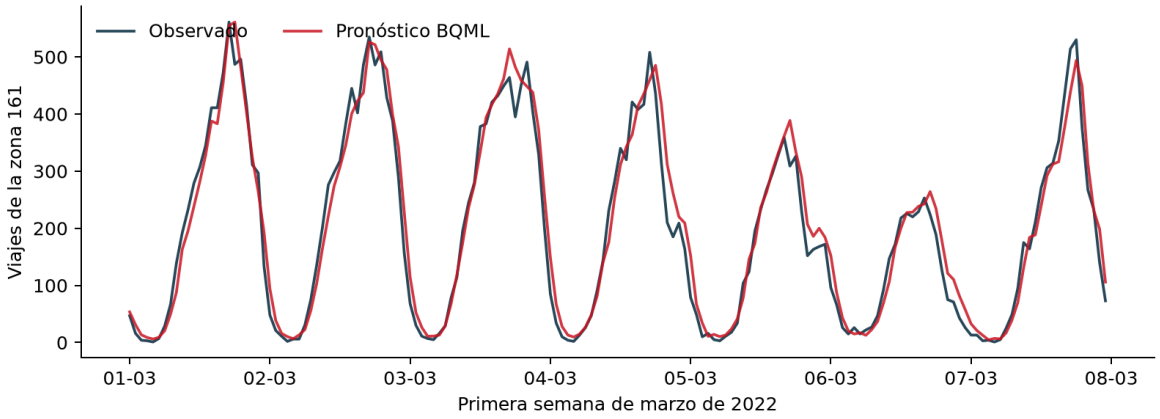


Figura 4. Zona 161, primera semana de marzo: ejemplo de consulta del prototipo. Las métricas abarcan todo marzo.

La regresión reduce el RMSE en 8,80 % frente a la referencia semanal. Sin embargo, su MAE de 3,301 y WAPE de 18,04 % son mayores que 3,186 y 17,41 % de esa referencia. Si se prioriza evitar errores grandes, la regresión resulta favorable; si se busca minimizar el error habitual con sencillez, la referencia semanal sigue siendo competitiva.

La evaluación no demuestra ahorro ni mejora de servicio. No se incorporan clima, eventos, intervalos de incertidumbre ni otros años; los viajes realizados no miden demanda insatisfecha. Antes de operar se requieren varios cortes temporales, revisión por zona y una función de costo de flota. Los resultados no se transfieren numéricamente a Punta Arenas.

8. Ejecución cloud y uso del prototipo

El experimento dejó tablas, modelo y trabajos ejecutados en BigQuery. resultados.json reúne controles, agregaciones, métricas, coeficientes, muestras y registros de ejecución; el respaldo conserva la grilla completa. La captura muestra la ejecución real, no una imagen de arquitectura propuesta.

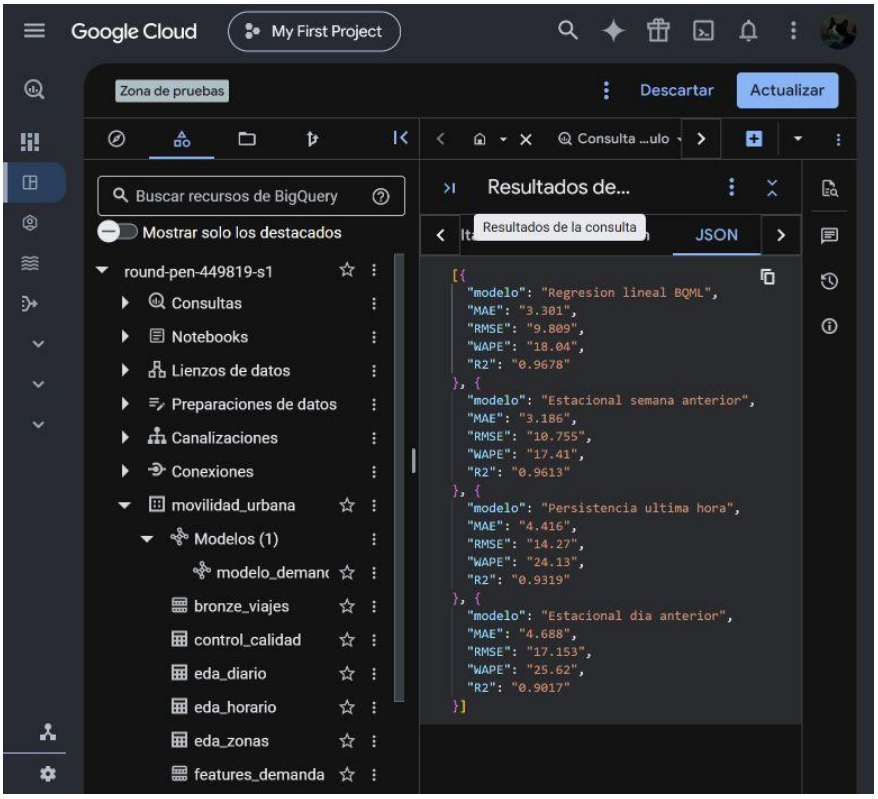


Figura 5. Proyecto Google Cloud con el modelo y las métricas del experimento.

Para revisar la entrega, abrir proyecto.ipynb en Jupyter o Google Colab y ejecutar las celdas en orden. Se muestran calidad, gráficos, comparación de modelos y una consulta por zona y hora. La demostración no necesita credenciales y conserva salidas ejecutadas.

Para reconstruir, usar un proyecto propio con BigQuery habilitado, autenticarse y activar RECONSTRUIR en el notebook. También se puede ejecutar python pipeline.py --proyecto TU_PROYECTO. La configuración se lee de configuracion.json y las fechas permanecen fijadas en SQL para mantener coherentes los controles. La reconstrucción reemplaza las tablas y el modelo del trabajo y consume cuotas.

Las muestras del prototipo incluyen zonas 132, 161 y 237 del 1 al 7 de marzo. El modelo y las métricas cloud incluyen las 263 zonas y todo marzo. La fuente tiene retraso de publicación: se trata de un prototipo histórico y no de un sistema de despacho en tiempo real.

9. Planificación y seguimiento individual

Vicente Yagello asume análisis de requisitos, arquitectura, ingeniería de datos, modelamiento, validación y documentación. El avance se organiza por entregables y dependencias: no se entrena hasta validar Gold ni se cierra el informe antes de contrastar métricas y revisar su presentación.

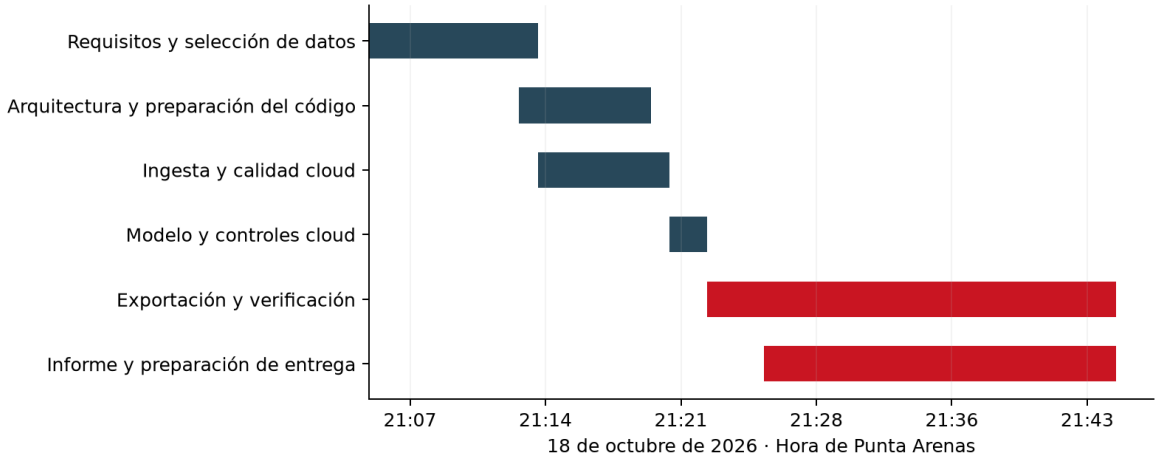


Figura 6. Hitos de preparación y ejecución. Los tiempos de los trabajos cloud respaldan la etapa experimental.

Etapa / producto	Responsable	Estado de cierre
Fuente y diseño / arquitectura	Vicente Yagello	Completado
Pipeline / capas y controles	Vicente Yagello	Completado
Modelo / prueba temporal	Vicente Yagello	Completado
Notebook y PDF / revisión	Vicente Yagello	Completado
Publicación / repositorio	Vicente Yagello	Completado

Incidencia real	Solución y comprobación
Particiones históricas caducadas	Rangos enteros; reconstrucción y conservación de 8.958.864 viajes
Acceso a metadatos regionales	Metadatos disponibles del dataset y registros de los trabajos
Descarga grande desde el navegador	Exportación por bloques; conciliación y verificación de series

La revisión final verifica los archivos mínimos, el enlace del repositorio, la ejecución del notebook y la legibilidad del PDF. La entrega en el ambiente de aprendizaje corresponde al estudiante: 19 de octubre de 2026 antes de las 18:00, con el nombre VYagello.pdf.

III. Conclusiones

Se implementó en Google Cloud un ciclo completo de ingesta, almacenamiento, calidad, análisis y predicción. Los 9.071.242 registros originales se transformaron en 8.958.864 viajes válidos y una grilla de 568.080 pares zona–hora. El almacenamiento particionado, el clustering y las validaciones hacen explícitas las decisiones de ingeniería.

La regresión lineal regularizada alcanzó RMSE 9,81 y R^2 0,9678 en marzo. Mejora el error cuadrático frente a la referencia semanal, pero no su MAE ni WAPE. El resultado permite discutir un compromiso operativo real y evita seleccionar un modelo únicamente por una métrica favorable.

La ejecución también mostró que una decisión habitual, como particionar por fechas históricas, puede fallar bajo restricciones del entorno. El cambio a rangos enteros permitió conservar los datos en sandbox. La disponibilidad depende del servicio administrado y de la reconstrucción por etapas; no se desplegó recuperación regional automática.

El prototipo es reproducible y permite revisar los resultados sin acceso al proyecto cloud. Su uso operativo exige datos oportunos, pruebas en otros periodos y una evaluación del costo de los errores. Estas condiciones delimitan el alcance académico sin atribuir beneficios que no fueron medidos.

IV. Referencias bibliográficas

[1] NYC Taxi and Limousine Commission. TLC Trip Record Data. Viajes y catálogo de zonas.

https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page

[2] Google Cloud. Try BigQuery using the sandbox. Cuotas, retención y restricciones.

https://docs.cloud.google.com/bigquery/docs/sandbox

[3] Google Cloud. Understand reliability. Disponibilidad y recuperación en BigQuery.

https://docs.cloud.google.com/bigquery/docs/reliability-intro

[4] Google Cloud. Estimate and control costs. Límites de bytes procesados.

https://docs.cloud.google.com/bigquery/docs/best-practices-costs

[5] Google Cloud. CREATE MODEL for generalized linear models. Regresión y validación.

https://docs.cloud.google.com/bigquery/docs/reference/standard-sql/bigqueryml-syntax-create-glm

Documentación consultada el 18 de octubre de 2026. Los resultados numéricos proceden del experimento ejecutado en BigQuery.

Repositorio: https://github.com/c3cla/bigdata-ev2-vicente