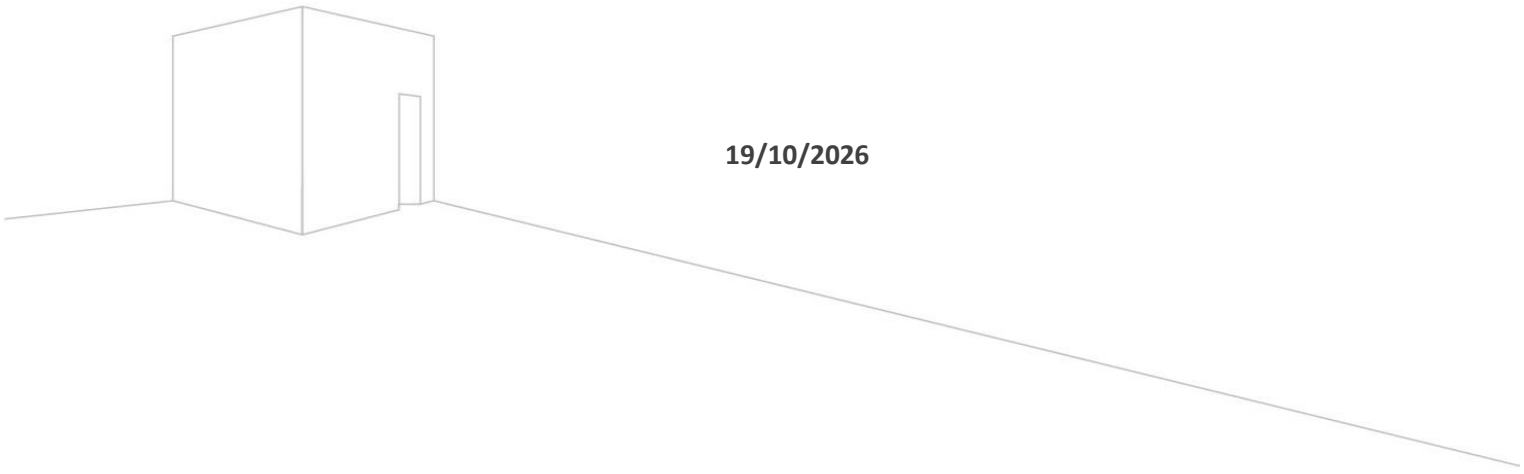
Predicción de viajes de taxi por zona y hora

Asignatura: Big Data TI3025

Nombre del académico: Paulo Simunovic Oyarzún

Nombre del estudiante: Vicente Yagello



19/10/2026

Contenido

I. Introducción. 3
1. Problema y herramientas seleccionadas....3
2. Resultado principal y entrega....3
II. Desarrollo 4
3. Arquitectura disponibilidad y seguridad 4
4. Tolerancia a fallos y evidencia del pipeline....5
5. Preparación y almacenamiento de los datos 6
6. Análisis descriptivo....7
7. Diseño del modelo y validación temporal....8
8. Resultados e interpretación 9
9. Diagnóstico territorial y decisión de uso....10
10. Ejecución cloud y uso del prototipo....11
11. Planificación y seguimiento individual....12
12. Bitácora de control y cierre....13
III. Conclusiones....14
IV. Referencias bibliográficas....15

I. Introducción.

Este trabajo desarrolla un pipeline en Google Cloud para analizar y predecir el número de viajes de taxis amarillos que comienzan en cada zona de Nueva York durante una hora. Se procesaron 9.071.242 registros de enero a marzo de 2022; después de validar fecha y zona, quedaron 8.958.864 viajes. Las transformaciones, el análisis descriptivo y el entrenamiento se ejecutaron en BigQuery.

El objetivo es integrar almacenamiento eficiente, procesamiento distribuido, controles de calidad y un modelo evaluado cronológicamente. El prototipo permite consultar predicciones históricas por zona y hora. Su aplicación potencial es apoyar la distribución de una flota, sin confundir viajes realizados con solicitudes no atendidas ni con el número de vehículos necesarios.

1. Problema y herramientas seleccionadas

Se eligió movilidad urbana porque ofrece millones de eventos, zonas oficiales y una variable objetivo interpretable. Frente a consumo eléctrico o comercio minorista, la fuente TLC permite relacionar directamente tiempo, territorio y volumen de actividad. Los datos son públicos, pero su cobertura se limita a taxis amarillos y a un trimestre histórico [1].

BigQuery sandbox reúne almacenamiento columnar, SQL distribuido y BigQuery ML en un solo entorno. Python y el notebook actúan como clientes; no simulan localmente un entrenamiento presentado como cloud. Esta alternativa reduce la administración de infraestructura y permite realizar el experimento sin activar facturación, sujeto a las cuotas y retención del servicio [2].

2. Resultado principal y entrega

La regresión obtuvo un RMSE de 9,81 viajes por zona y hora, frente a 10,75 de una referencia semanal: una reducción del 8,80 %. Sin embargo, la referencia semanal obtuvo mejores MAE y WAPE. Por tanto, la decisión depende del costo de los errores grandes y no de una supuesta superioridad en todas las métricas.

El repositorio contiene únicamente pipeline.py, proyecto.ipynb, configuracion.json, resultados.json, demanda_horaria.parquet y este informe PDF. El notebook incluye las instrucciones de ejecución y las comprobaciones; no se requieren documentos auxiliares.

https://github.com/c3cla/bigdata-ev2-vicente

II. Desarrollo

3. Arquitectura disponibilidad y seguridad

La solución utiliza el proyecto round-pen-449819-s1, dataset movilidad_urbana, ubicación US. Bronze conserva los registros originales; Silver valida el universo; Gold completa los conteos por zona y hora; la capa de variables alimenta el modelo y la evaluación.

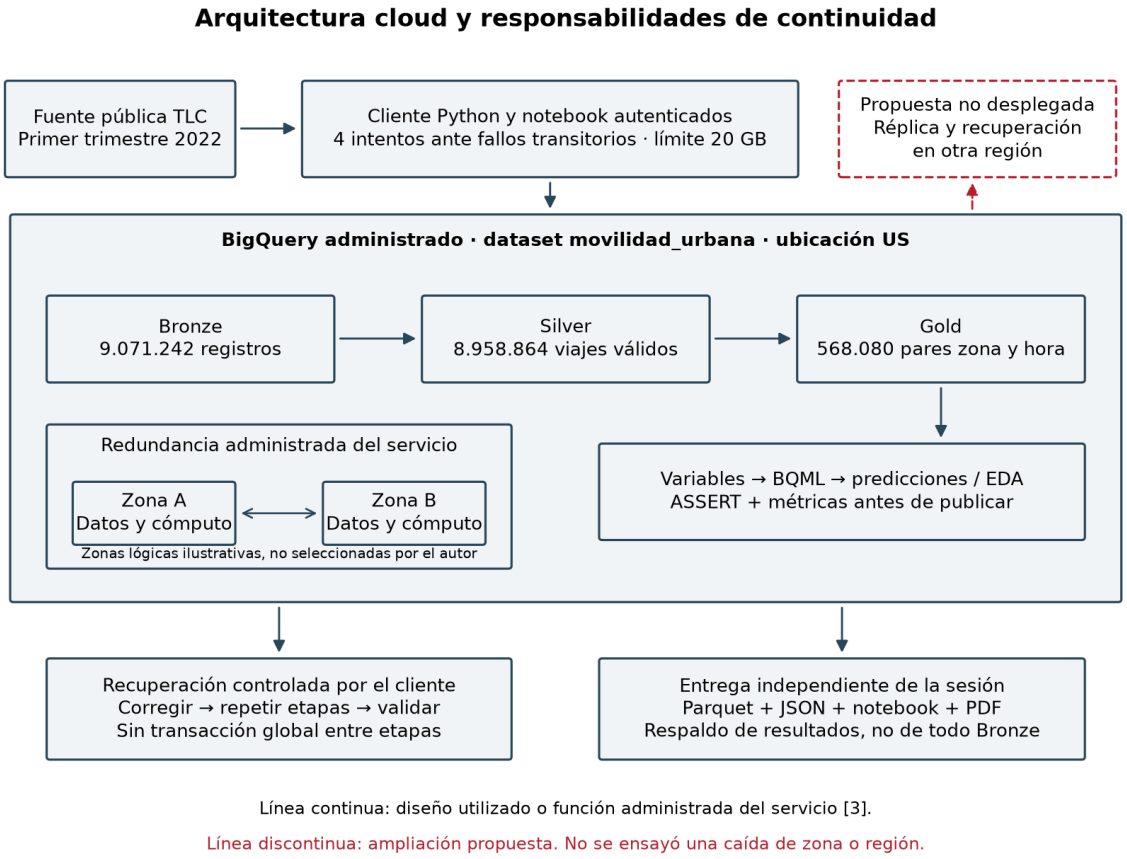


Figura 1. Mecanismos explícitos de continuidad. Las funciones administradas del servicio no equivalen a pruebas de caída realizadas por el autor.

BigQuery administra redundancia de almacenamiento y cómputo entre zonas, distribuye las consultas y escala recursos. El cliente controla reintentos, reconstrucción y validación. La ubicación US no proporciona por sí sola una réplica regional [3].

Se utilizó la sesión Google del autor, sin claves publicadas. La automatización futura debería separar permisos de ejecución y escritura al dataset; no se afirma que exista una cuenta de servicio. El procesamiento batch corresponde a una fuente histórica, no a un flujo de despacho en tiempo real.

4. Tolerancia a fallos y evidencia del pipeline

Riesgo	Mecanismo y responsable	Evidencia o límite
Fallo de máquina o zona	Redundancia zonal y reasignación administradas por BigQuery	Función del servicio [3]; sin ensayo de caída
Error transitorio de API	Cliente: cuatro intentos y esperas de 1, 2 y 4 segundos	Código y pruebas unitarias; no garantiza recuperación regional
Error de datos o SQL	Detener, corregir y reconstruir etapas dependientes	Fallo sin filas y reconstrucción registrados
Cierre del cliente	Tablas y modelo permanecen en el servicio	No dependen de mantener abierto el notebook
Pérdida regional o caducidad	Reconstrucción desde fuente y código; resultados exportados	Sin réplica activa, RTO o RPO medidos

El procedimiento de recuperación es identificar el job_id y el error, corregir la causa, repetir desde la etapa afectada y aprobar los cinco ASSERT antes de usar la nueva salida. CREATE OR REPLACE evita anexar duplicados, pero no existe publicación atómica entre todas las etapas. La interrupción regional y la pérdida de la fuente requieren medidas adicionales, no cubiertas por los reintentos.

Capa	Filas	Organización cloud
Bronze	9.071.242	Mes entero; clustering por zona de origen
Silver	8.958.864	Rangos de zona; clustering por fecha y hora
Gold	568.080	Rangos de zona; clustering por hora
Variables	523.896	Misma partición; siete días de calentamiento
Predicciones	195.672	Misma partición; prueba de marzo

Los volúmenes proceden de los metadatos exportados en resultados.json. La ingesta exitosa leyó 7.487.651.196 bytes de la fuente; Bronze registra 1.874.033.402 bytes lógicos y Gold 13.633.920. No son medidas de compresión física ni una comparación experimental con tablas sin partición. La organización permite poda por mes o zona y evita volver a analizar los eventos para cada consulta horaria.

El proyecto permanece sin facturación activada. El límite por consulta es 20 GB; las cuotas del sandbox y la caducidad a 60 días siguen aplicando [2, 4]. Los metadatos son una fotografía del experimento, no un cálculo del consumo acumulado ni una promesa de disponibilidad permanente.

5. Preparación y almacenamiento de los datos

La fuente es bigquery-public-data.new_york_taxi_trips.tlc_yellow_trips_2022. Se seleccionaron los meses de archivo 1 a 3. Silver exige inicio desde el 1 de enero, anterior al 1 de abril, y zona de origen entre 1 y 263.

Control	Registros	Tratamiento
Originales	9.071.242	Conservar en Bronze
Fecha nula / fuera del periodo	0 / 110	Excluir del universo
Zona inválida	112.268	Excluir del universo
Importe negativo	48.588	Auditar; no es predictor
Llegada anterior a salida	4.685	Auditar; no usar duración
Distancia negativa	0	Control de calidad
Viajes válidos	8.958.864	Universo analítico

Se excluyeron 112.378 registros, el 1,24 %. Los controles pueden superponerse; no deben sumarse como categorías excluyentes. No se deduplica por zona y hora porque múltiples viajes pueden compartir ambas y no existe una clave única confiable. Los importes y duraciones anómalos no invalidan automáticamente un inicio útil para contar viajes.

Bronze se particiona por mes entero de archivo y se agrupa por zona. Silver, Gold, variables y predicciones usan rangos enteros de zona de amplitud 16 y clustering temporal. Las primeras particiones por fechas de 2022 caducaban en el sandbox y dejaban tablas vacías; los rangos enteros resolvieron el problema sin cambiar los datos analizados.

Gold cruza 263 zonas con 2.160 horas: 568.080 filas, incluyendo ceros mediante LEFT JOIN. Así, un rezago de 24 filas equivale a 24 horas. El almacenamiento cloud es columnar; el respaldo demanda_horaria.parquet usa Snappy. Se verificaron volumen, unicidad, cobertura y las huellas de las 263 zonas.

La reconstrucción desde los Parquet oficiales actuales mostró dos viajes adicionales frente a la copia BigQuery. Se conciliaron las dos series afectadas y el respaldo conserva el universo del experimento; la diferencia se registra en resultados.json. Se mantienen las etiquetas temporales de la fuente sin una segunda conversión de huso; el horario de verano exige revisión antes de una operación real.

6. Análisis descriptivo

Las agregaciones se ejecutaron con SQL sobre Gold. El promedio diario fue 99.543 viajes, la mediana 100.050, el mínimo 34.064 y el máximo 127.799. Las diez zonas de mayor actividad concentraron el 36,61 % del volumen, por lo que una asignación uniforme de vehículos no refleja la distribución observada.

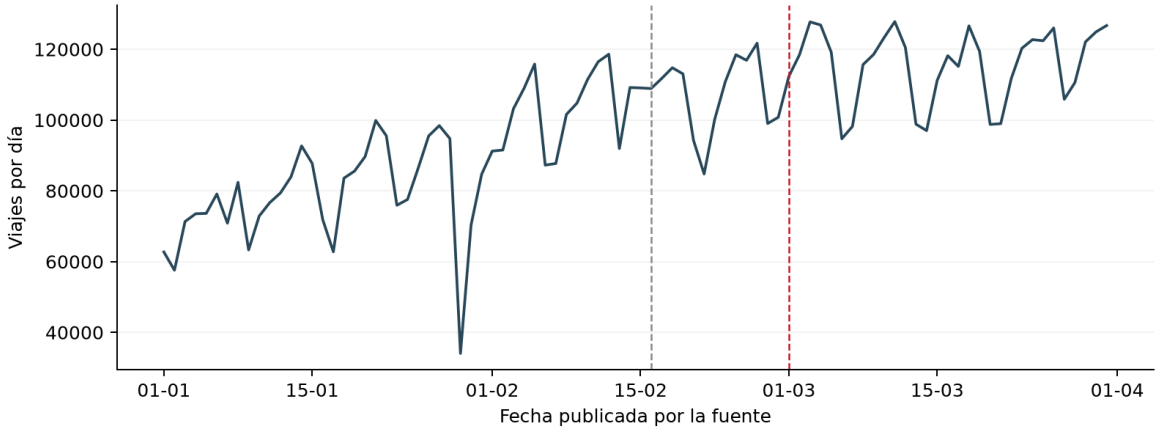


Figura 2. Viajes diarios; líneas verticales: comienzo de validación y prueba.

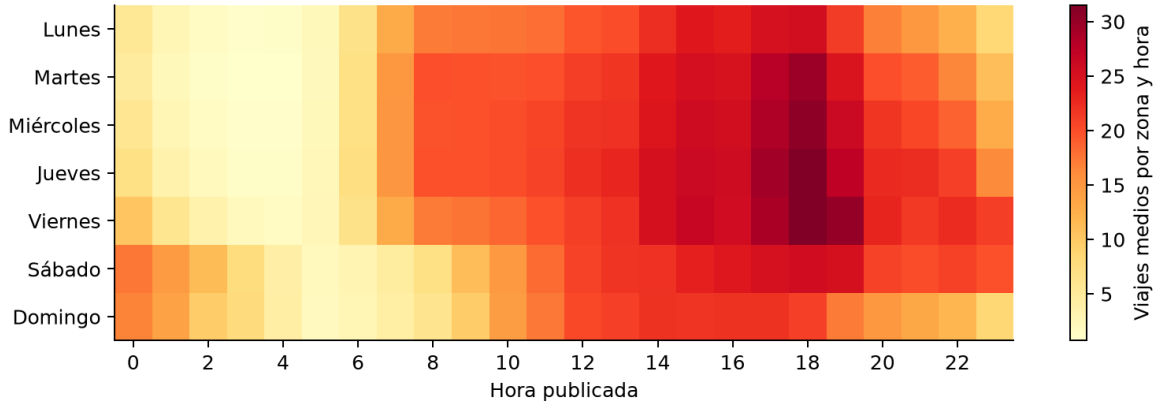


Figura 3. Intensidad media por zona, día y hora, incluyendo horas sin viajes.

El 64,73 % de las celdas zona–hora tiene cero viajes. Se utiliza WAPE agregado en lugar de MAPE por observación, que divide por cero. Los patrones justifican rezagos diarios y semanales, sin atribuir causalidad a clima, políticas o eventos que no fueron medidos.

7. Diseño del modelo y validación temporal

La variable objetivo es el conteo de inicios por zona y hora. Se predice una hora adelante suponiendo disponibles las observaciones anteriores. Se excluyen del modelamiento tarifas, propinas, destino y duración del mismo viaje, porque podrían aportar información posterior al momento de decisión.

Variables	Construcción
rezago_1, rezago_24, rezago_168	Viajes de 1, 24 y 168 horas antes
media_24h	Promedio de las 24 horas anteriores; excluye el objetivo
seno_hora, coseno_hora	Codificación cíclica de la hora
zona, dia_semana	Categorías conocidas al emitir el pronóstico

Se entrenó una regresión lineal BigQuery ML con regularización L2 = 1 y separación CUSTOM mediante una columna booleana de validación. BigQuery ML administra la codificación categórica y el tratamiento numérico. La primera semana se reserva para formar rezagos; no se seleccionan hiperparámetros mirando marzo [5].

Conjunto	Periodo 2022	Filas
Entrenamiento	8 de enero a 15 de febrero	246.168
Validación	16 a 28 de febrero	82.056
Prueba	1 a 31 de marzo	195.672

El modelo se mantiene fijo en marzo, pero los rezagos pueden incorporar horas de marzo que ya transcurrieron. Es una evaluación secuencial de una hora adelante, no un pronóstico de todo el mes emitido en febrero. Las predicciones negativas se recortan a cero antes de evaluar.

El siguiente fragmento del pipeline documenta cómo se evita incluir el valor objetivo en la media móvil:

```
AVG(viajes) OVER (
  PARTITION BY zona_id ORDER BY hora
  ROWS BETWEEN 24 PRECEDING AND 1 PRECEDING
) AS media_24h
```

El notebook comprueba los rezagos y la media contra el respaldo completo. Las cinco validaciones SQL revisan volumen, conservación, predicciones válidas, igualdad del conjunto de prueba y ausencia de variables faltantes.

8. Resultados e interpretación

Modelo	MAE	RMSE	WAPE	R^2
Regresion lineal BQML	3,301	9,809	18,04 %	0,9678
Estacional semana anterior	3,186	10,755	17,41 %	0,9613
Persistencia ultima hora	4,416	14,270	24,13 %	0,9319
Estacional dia anterior	4,688	17,153	25,62 %	0,9017

Los cuatro métodos usan las mismas 195.672 filas de prueba. MAE expresa el error absoluto medio; RMSE penaliza más los errores grandes; WAPE relaciona el error absoluto total con el volumen observado; R^2 compara el error cuadrático con una predicción constante.

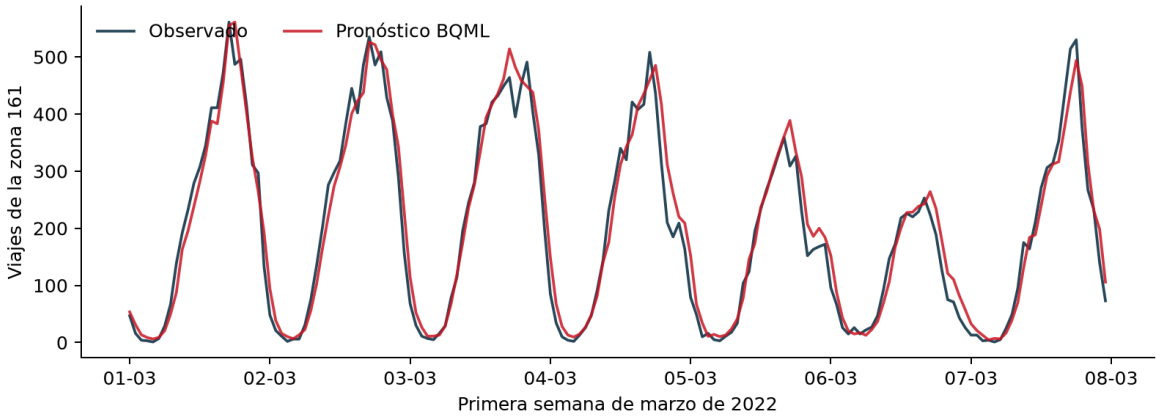


Figura 4. Zona 161, primera semana de marzo: ejemplo de consulta del prototipo. Las métricas abarcan todo marzo.

La regresión reduce el RMSE en 8,80 % frente a la referencia semanal. Sin embargo, su MAE de 3,301 y WAPE de 18,04 % son mayores que 3,186 y 17,41 % de esa referencia. Si se prioriza evitar errores grandes, la regresión resulta favorable; si se busca minimizar el error habitual con sencillez, la referencia semanal sigue siendo competitiva.

La evaluación no demuestra ahorro ni mejora de servicio. No se incorporan clima, eventos, intervalos de incertidumbre ni otros años; los viajes realizados no miden demanda insatisfecha. Antes de operar se requieren varios cortes temporales, revisión por zona y una función de costo de flota. Los resultados no se transfieren numéricamente a Punta Arenas.

9. Diagnóstico territorial y decisión de uso

Se presentan las seis zonas de mayor volumen de marzo. Sus métricas se calcularon en BigQuery sobre 744 horas cada una, no desde la muestra del prototipo.

Zona	Viajes de marzo	MAE	RMSE	WAPE
237	168.295	27,62	37,79	12,21 %
132	152.728	37,35	47,56	18,19 %
161	152.353	29,11	40,68	14,21 %
236	152.289	27,69	39,16	13,53 %
162	122.271	22,09	29,60	13,44 %
186	118.396	24,78	33,78	15,57 %

Los cuatro grupos ordenan las 263 zonas por volumen de marzo. Es un diagnóstico retrospectivo, no utilizado para entrenar, seleccionar variables ni ajustar el modelo.

Grupo	Zonas	Viajes	RMSE	WAPE
Q1 menor volumen	66	1.195	0,684	1.771,17 %
Q2	66	6.608	0,792	369,29 %
Q3	65	34.385	1,334	117,91 %
Q4 mayor volumen	66	3.538.473	19,507	15,82 %

El grupo de menor volumen registra apenas 1.195 viajes y RMSE 0,684, pero WAPE 1.771,17 %. El error absoluto pequeño puede superar ampliamente un denominador mínimo. Ocho zonas no tuvieron viajes en marzo; su WAPE individual no está definido y no debe reemplazarse por cero. Los porcentajes de grupo se recalculan desde errores absolutos y volumen, sin promediar porcentajes por zona.

No se recomienda aplicar el pronóstico uniformemente. En áreas activas debe valorarse el costo de errores grandes; en áreas escasas, comparar una referencia de cero o modelos de conteo usando entrenamiento y validación. Esta mejora queda propuesta. Sin referencias semanales por zona no se afirma superioridad territorial; la referencia semanal conserva mejor MAE y WAPE globales.

10. Ejecución cloud y uso del prototipo

El experimento dejó tablas, modelo y trabajos ejecutados en BigQuery. resultados.json reúne controles, agregaciones, métricas, coeficientes, muestras y registros de ejecución; el respaldo conserva la grilla completa. La captura muestra la ejecución real, no una imagen de arquitectura propuesta.

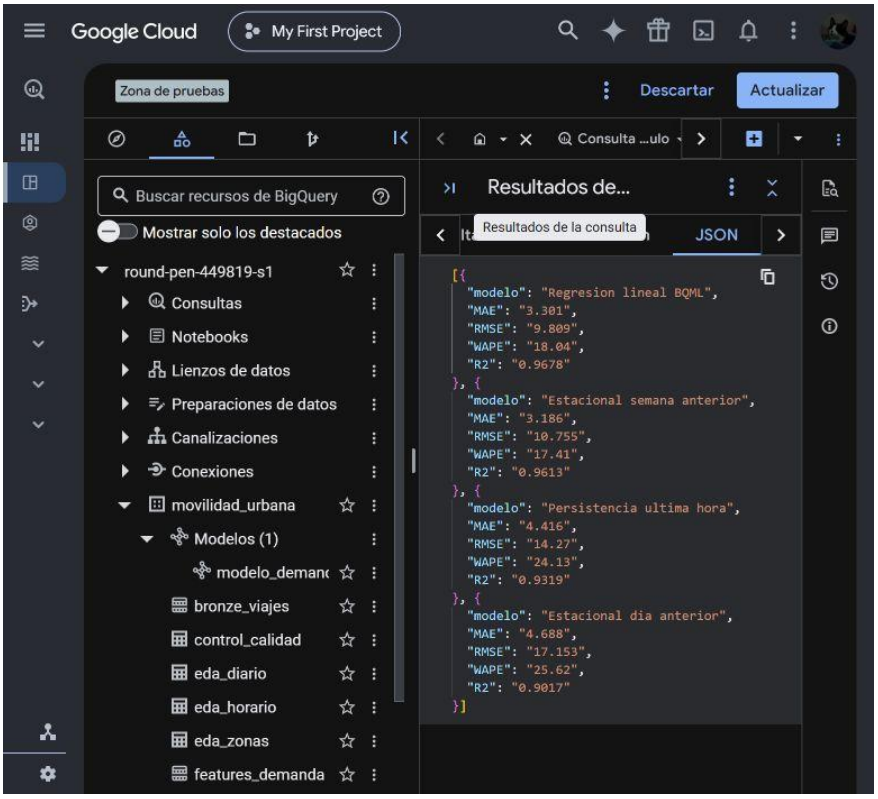


Figura 5. Proyecto Google Cloud con el modelo y las métricas del experimento.

Para revisar la entrega, abrir proyecto.ipynb en Jupyter o Google Colab y ejecutar las celdas en orden. Se muestran calidad, gráficos, comparación de modelos y una consulta por zona y hora. La demostración no necesita credenciales y conserva salidas ejecutadas.

Para reconstruir, usar un proyecto propio con BigQuery habilitado, autenticarse y activar RECONSTRUIR en el notebook. También se puede ejecutar python pipeline.py --proyecto TU_PROYECTO. La configuración se lee de configuracion.json y las fechas permanecen fijadas en SQL para mantener coherentes los controles. La reconstrucción reemplaza las tablas y el modelo del trabajo y consume cuotas.

Las muestras del prototipo incluyen zonas 132, 161 y 237 del 1 al 7 de marzo. El modelo y las métricas cloud incluyen las 263 zonas y todo marzo. La fuente tiene retraso de publicación: se trata de un prototipo histórico y no de un sistema de despacho en tiempo real.

11. Planificación y seguimiento individual

Vicente Yagello asume análisis de requisitos, arquitectura, ingeniería de datos, modelamiento, validación y documentación. El avance se organiza por entregables y dependencias: no se entrena hasta validar Gold ni se cierra el informe antes de contrastar métricas y revisar su presentación.

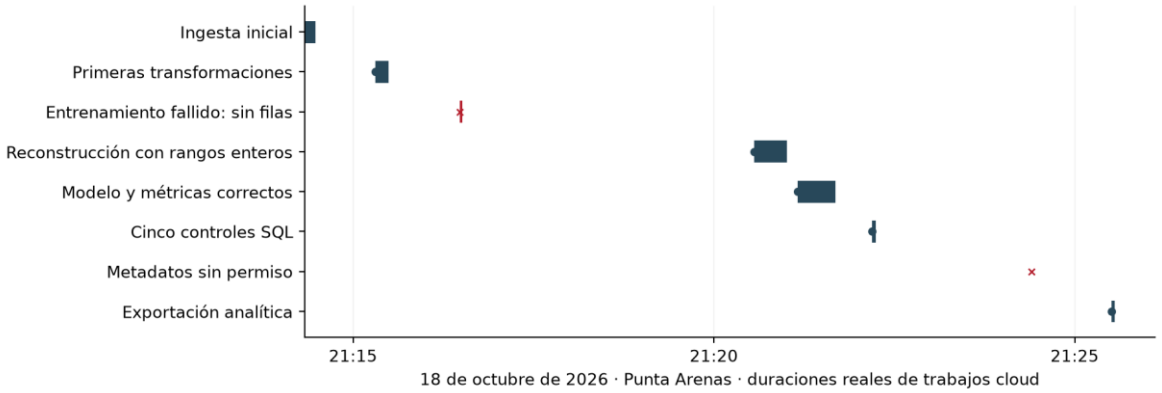


Figura 6. Gantt de ejecución registrado por BigQuery, no estimación del tiempo de trabajo personal. Azul: sin error; rojo: fallo. Los puntos permiten ver tareas de pocos segundos.

Rol individual	Competencia aplicada	Producto y control
Arquitectura	Diseñar capas, recuperación y límites	Diagrama y decisiones de continuidad
Ingeniería de datos	SQL, particiones y consistencia	Bronze–Gold; conservación del volumen
Análisis y modelamiento	Explorar y validar series temporales	EDA, cortes cronológicos y referencias
Validación y documentación	Contrastar evidencias y comunicar	ASSERT, notebook ejecutado y PDF revisado

En esta modalidad individual, Vicente Yagello ejerce los roles por fase. Las competencias requeridas se vinculan con un producto verificable. La revisión por productos y criterios de cierre reduce el riesgo de omitir controles cuando la ejecución y la revisión dependen de una sola persona.

El cronograma usa start_time y end_time de los trabajos, convertidos de UTC a Punta Arenas. Su alcance es el seguimiento verificable de la ejecución técnica. El diseño y la documentación se controlan mediante sus productos, porque no se dispone de un registro de sus duraciones.

12. Bitácora de control y cierre

La bitácora conserva fallos y decisiones. Cada identificador abreviado permite localizar el job_id completo en resultados.json. Las horas corresponden al 18 de octubre de 2026 en Punta Arenas; DONE solo significa finalizado: un trabajo con error no se considera exitoso.

Hora	Hallazgo y decisión	Evidencia
21:14	Ingesta inicial; comprobar el volumen antes de continuar	job_vQDzzrB…
21:16	Entrenamiento sin filas; detener y revisar persistencia	job_V3RJ9RF…
21:20	Rangos enteros y reconstrucción; verificar Silver y Gold	job_WfmBy1Y…
21:21	Entrenamiento y métricas; comparar las cuatro alternativas	job_lL6oRnA…
21:22	Cinco ASSERT aprobados; habilitar revisión de resultados	job_M7nz1Od…
21:24	Metadatos regionales sin permiso; usar alcance del dataset	job_0ksfV0e…
21:25	Exportación analítica sin error; contrastar resultados	job_-goNz7p…

El 19 de octubre a las 16:46 se registró la primera publicación del repositorio simplificado, commit 3202bea. La revisión posterior refuerza disponibilidad, diagnóstico territorial y trazabilidad manteniendo seis archivos. El historial Git permite distinguir la primera entrega de esta mejora sin atribuir al pasado controles realizados después.

Puerta de control	Dependencia	Criterio de aprobación
Datos listos	Bronze → Silver → Gold	568.080 pares únicos y total conservado
Modelo evaluable	Variables y cortes temporales	Sin nulos ni uso de horas futuras
Resultado comparable	Predicciones de marzo	Cuatro métodos sobre 195.672 filas
Entrega cerrada	Notebook y PDF actualizados	Celdas sin error, páginas legibles y enlace válido

Ante una incidencia se marca el producto como bloqueado, se corrige y se repite su control antes de continuar. El cierre deja los resultados y el historial en GitHub. La subida al ambiente de aprendizaje corresponde al estudiante: 19 de octubre de 2026 antes de las 18:00, con el nombre VYagello.pdf.

III. Conclusiones

Se implementó en Google Cloud un ciclo completo de ingesta, almacenamiento, calidad, análisis y predicción. Los 9.071.242 registros originales se transformaron en 8.958.864 viajes válidos y una grilla de 568.080 pares zona–hora. El almacenamiento particionado, el clustering y las validaciones hacen explícitas las decisiones de ingeniería.

La regresión lineal regularizada alcanzó RMSE 9,81 y R^2 0,9678 en marzo. Mejora el error cuadrático frente a la referencia semanal, pero no su MAE ni WAPE. El resultado permite discutir un compromiso operativo real y evita seleccionar un modelo únicamente por una métrica favorable.

La ejecución también mostró que una decisión habitual, como particionar por fechas históricas, puede fallar bajo restricciones del entorno. El cambio a rangos enteros permitió conservar los datos en sandbox. La disponibilidad depende del servicio administrado y de la reconstrucción por etapas; no se desplegó recuperación regional automática.

El prototipo es reproducible y permite revisar los resultados sin acceso al proyecto cloud. Su uso operativo exige datos oportunos, pruebas en otros periodos y una evaluación del costo de los errores. Estas condiciones delimitan el alcance académico sin atribuir beneficios que no fueron medidos.

IV. Referencias bibliográficas

[1] NYC Taxi and Limousine Commission. TLC Trip Record Data. Viajes y catálogo de zonas.

https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page

[2] Google Cloud. Try BigQuery using the sandbox. Cuotas, retención y restricciones.

https://docs.cloud.google.com/bigquery/docs/sandbox

[3] Google Cloud. Understand reliability. Disponibilidad y recuperación en BigQuery.

https://docs.cloud.google.com/bigquery/docs/reliability-intro

[4] Google Cloud. Estimate and control costs. Límites de bytes procesados.

https://docs.cloud.google.com/bigquery/docs/best-practices-costs

[5] Google Cloud. CREATE MODEL for generalized linear models. Regresión y validación.

https://docs.cloud.google.com/bigquery/docs/reference/standard-sql/bigqueryml-syntax-create-glm

Documentación consultada el 18 de octubre y revisada el 19 de octubre de 2026. Los resultados numéricos proceden del experimento ejecutado en BigQuery; el diagnóstico por grupos se deriva de sus agregados exportados.

Repositorio: https://github.com/c3cla/bigdata-ev2-vicente